

Wahrscheinlichkeitstheorie und Statistik - Zusammenfassung

Julian Shen

28. Januar 2022

1 Grundbegriffe

Definition: Ergebnisse und Ereignisse

- **Grundraum** ist eine nicht leere Menge $\Omega \neq \emptyset$ und enthält alle möglichen **Ergebnisse** eines Zufallsexperiments
- **Ereignisse** sind Teilmengen $A \subseteq \Omega$, denen eine Wahrscheinlichkeit zugeordnet werden kann. Falls ein ω Ergebnis ist, dann heißt $\{\omega\}$ **Elementarereignis**

Ereignisse können durch Mengenoperationen logisch verknüpft werden:

- $A \cup B$: Ereignis A oder B tritt ein („inklusives oder“)
- $A \cap B$: Ereignis A und B treffen ein
- $A \setminus B$: Ereignis A tritt ein, aber Ereignis B trifft nicht ein
- B^c : Ereignis B trifft nicht ein
- $A \subseteq B$: Wenn A eintritt, dann tritt auch B ein

Jedem Ereignis kann durch die **relative Häufigkeit** eine Wahrscheinlichkeit zugeordnet werden. Für n Wiederholungen und Ergebnisse $\omega_1, \dots, \omega_n \in \Omega$ gilt:

$$\mathbb{P}_n(A) := \frac{1}{n} \sum_{i=1}^n \mathbb{1}_{\{\omega_i \in A\}}$$

Definition: Diskretes Wahrscheinlichkeitsmaß und Wahrscheinlichkeitsraum

Eine Abbildung $\mathbb{P} : \mathcal{P}(\Omega) \rightarrow [0, 1]$ heißt **diskretes Wahrscheinlichkeitsmaß**, falls

- $\mathbb{P}(\Omega) = 1$
- $\forall A_n \subseteq \Omega, n \in \mathbb{N}, \text{ disjunkt: } \mathbb{P}\left(\bigcup_{n \in \mathbb{N}} A_n\right) = \sum_{i=1}^{\infty} \mathbb{P}(A_n)$ (σ -Additivität)
- es existiert eine abzählbare Menge $\Omega_0 \subseteq \Omega$ mit $\mathbb{P}(\Omega_0) = 1$

Dann heißt (Ω, \mathbb{P}) **diskreter Wahrscheinlichkeitsraum**.

Rechenregeln für diskrete Wahrscheinlichkeitsräume

- $\mathbb{P}(\emptyset) = 0$
- $\mathbb{P}(A^c) = 1 - \mathbb{P}(A)$
- $\mathbb{P}(B \setminus A) = \mathbb{P}(B) - \mathbb{P}(A)$
- $\mathbb{P}(A \cup B) = \mathbb{P}(A) + \mathbb{P}(B) - \mathbb{P}(A \cap B)$

Definition: Bernoulliverteilung

Wahrscheinlichkeitsverteilung heißt Bernoulliverteilung Ber_p mit Erfolgswahrscheinlichkeit p , wenn:

- Grundraum $\Omega = \{0, 1\}$
- $\mathbb{P}(1) = p$ für ein $p \in [0, 1]$

Es gilt $\mathbb{P}(\{0\}) = 1 - \mathbb{P}(\{1\}) = 1 - p$

Definition: Gleichverteilung

Das Wahrscheinlichkeitsmaß (Ω, \mathbb{P}) heißt Gleichverteilung oder **Laplace-Verteilung** U_A auf Ω , falls

- $\Omega \neq \emptyset$ endlich
- $\mathbb{P}(A) = \frac{|A|}{|\Omega|}$, für $A \subseteq \Omega$

Urnenmodelle/Fächermodelle

| Urnenmodell mit n Kugeln und k Ziehungen | mit Zurücklegen | ohne Zurücklegen | |
|--|-------------------------|--------------------------|---|
| mit Reihenfolge | n^k | $\frac{n!}{(n-k)!}$ | unterscheidbare Murmeln |
| ohne Reihenfolge | $\binom{n+k-1}{k}$ | $\binom{n}{k}$ | ununterscheidbare Murmeln |
| | mit Mehrfachbelegung | ohne Mehrfachbelegung | Verteilung von k Murmeln auf n Fächer |

Urnenmodelle ermöglichen es, die Wahrscheinlichkeiten zu bestimmen, falls von einer Gleichverteilung ausgegangen werden kann!

Definition: Zähldichte

Sei (Ω, \mathbb{P}) ein diskreter Wahrscheinlichkeitsraum. Dann wird die Funktion

$$f : \Omega \rightarrow [0, 1], f(\omega) = \mathbb{P}(\{\omega\})$$

Wahrscheinlichkeitsfunktion oder **Zähldichte** von \mathbb{P} genannt.

Diese besitzt folgende Eigenschaften:

- $\Omega_T := \{\omega \in \Omega \mid f(\omega) > 0\}$ ist abzählbar und heißt **Träger** von \mathbb{P} bzw. von f
- $\sum_{\omega \in \Omega} f(\omega) = 1$

Die Zähldichte ist eindeutig!

Definition: Binomialverteilung

Das Wahrscheinlichkeitsmaß $\mathbb{P} = \text{Bin}_{(n,p)}$ auf $\{0, \dots, n\}$ mit der Zähldichte

$$f(k) = \binom{n}{k} p^k \cdot (1-p)^{n-k} \quad \forall k \in \{0, \dots, n\}$$

heißt **Binomialverteilung** mit Parametern $n \in \mathbb{N}$ und $p \in [0, 1]$.

Definition: Geometrische Verteilung

Das Wahrscheinlichkeitsmaß $\mathbb{P} = \text{Geo}_p$ auf \mathbb{N}_0 mit der Zähldichte

$$f(k) = (1-p)^k \cdot p \quad \forall k \in \mathbb{N}_0$$

heißt **geometrische Verteilung** mit Parameter $p \in (0, 1]$.

2 Bedingte Wahrscheinlichkeit und Unabhängigkeit

Definition: Bedingte Wahrscheinlichkeit

Für (Ω, \mathbb{P}) diskreter Wahrscheinlichkeitsraum und $A, B \in \Omega$ mit $\mathbb{P}(B) > 0$ heißt

$$\mathbb{P}(A \mid B) := \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)}$$

die **bedingte Wahrscheinlichkeit** von A gegeben B.

Multiplikationsformel

Seien $A_1, \dots, A_n \subseteq \Omega$ Ereignisse mit $\mathbb{P}(A_1 \cap \dots \cap A_{n-1}) > 0$, dann gilt

$$\mathbb{P}(A_1 \cap \dots \cap A_{n-1}) = \mathbb{P}(A_1) \cdot \mathbb{P}(A_2 \mid A_1) \cdot \mathbb{P}(A_3 \mid A_1 \cap A_2) \cdots \mathbb{P}(A_n \mid A_1 \cap \dots \cap A_{n-1})$$

Im Fall von $n=2$ gilt: $\mathbb{P}(A \cap B) = \mathbb{P}(B) \cdot \mathbb{P}(A \mid B)$

Satz von der totalen Wahrscheinlichkeit und Satz von Bayes

Sei (Ω, \mathbb{P}) ein diskreter Wahrscheinlichkeitsraum, I eine abzählbare Indexmenge, $B_i \subseteq \Omega, i \in I$, disjunkt mit $\mathbb{P}(B_i) > 0$ und $\bigcup_{i \in I} B_i = \Omega$ und $A \subseteq \Omega$ beliebig.

- Es gilt der **Satz von der totalen Wahrscheinlichkeit**:

$$\mathbb{P}(A) = \sum_{i \in I} \mathbb{P}(A \mid B_i) \cdot \mathbb{P}(B_i)$$

- Falls $\mathbb{P}(A) > 0$ und $k \in I$, dann gilt der **Satz von Bayes**:

$$\mathbb{P}(B_k \mid A) = \frac{\mathbb{P}(A \mid B_k) \cdot \mathbb{P}(B_k)}{\mathbb{P}(A)} = \frac{\mathbb{P}(A \mid B_k) \cdot \mathbb{P}(B_k)}{\sum_{i \in I} \mathbb{P}(A \mid B_i) \cdot \mathbb{P}(B_i)}$$

Definition: Stochastische Unabhängigkeit

Sei (Ω, \mathbb{P}) ein diskreter Wahrscheinlichkeitsraum. Zwei Ereignisse $A, B \subseteq \Omega$ heißen **stochastisch unabhängig**, falls

$$\mathbb{P}(A \cap B) = \mathbb{P}(A) \cdot \mathbb{P}(B)$$

Ereignisse $A_1, \dots, A_n \subseteq \Omega$ heißen **stochastisch unabhängig**, wenn für jede Indexmenge $I \subseteq \{1, \dots, n\}, I \neq \emptyset$, gilt

$$\mathbb{P}\left(\bigcap_{i \in I} A_i\right) = \prod_{i \in I} \mathbb{P}(A_i)$$

Achtung: Mehr als zwei Ereignisse A_1, \dots, A_n sind im Allgemeinen nicht stochastisch unabhängig, wenn nur $\mathbb{P}\left(\bigcap_{i=1}^n A_i\right) = \prod_{i=1}^n \mathbb{P}(A_i)$ gilt! Gleiches gilt, wenn jeweils nur zwei der Ereignisse stochastisch unabhängig sind.

3 Zufallsvariablen und ihre Verteilungen

Definition: S -wertige Zufallsvariable

Ist (Ω, \mathbb{P}) ein diskreter Wahrscheinlichkeitsraum und $S \neq \emptyset$ eine beliebige Menge, so wird die Abbildung $X : \Omega \rightarrow S$ **S -wertige Zufallsvariable** genannt.

Definition: Verteilung

Ist $X : \Omega \rightarrow S$ eine Zufallsvariable auf einem diskreten Wahrscheinlichkeitsraum (Ω, \mathbb{P}) , dann wird durch

$$\mathbb{P}^X(B) := \mathbb{P}(X^{-1}(B)) \quad \forall B \subseteq S$$

ein Wahrscheinlichkeitsmaß \mathbb{P}^X auf S definiert, welches Verteilung von X genannt wird. (S, \mathbb{P}^X) ist ein diskreter Wahrscheinlichkeitsraum. Notation für Urbilder:

- $\{X \in B\} := \{\omega \in \Omega \mid X(\omega) \in B\} = X^{-1}(B)$
- $\{X = x\} := \{\omega \in \Omega \mid X(\omega) = x\} = X^{-1}(\{x\})$
- $\{X > x\} := \{\omega \in \Omega \mid X(\omega) > x\} = X^{-1}((x, \infty))$

Zudem schreibt man $\mathbb{P}(X \in B) := \mathbb{P}(\{X \in B\})$

Definition: Stochastische Unabhängigkeit von Zufallsvariablen

Sei (Ω, \mathbb{P}) ein diskreter Wahrscheinlichkeitsraum und $S_i, i \in \{1, \dots, n\}$ nichtleere Zufallsvariablen. Zufallsvariablen $X_i : \Omega \rightarrow S_i, i \in \{1, \dots, n\}$ heißen **stochastisch unabhängig**, wenn für beliebige $B_i \subseteq S_i$ die Ereignisse $\{X_1 \in B_1\}, \dots, \{X_n \in B_n\}$ stochastisch unabhängig sind.

Auch der Vektor $(X_1, \dots, X_n) : \Omega \rightarrow S_1 \times \dots \times S_n$ ist eine Zufallsvariable mit Verteilung $\mathbb{P}^{(X_1, \dots, X_n)}$ auf $S_1 \times \dots \times S_n$.

Bemerkung zur Schreibweise: $(X_1 \in B_1, X_2 \in B_2) = (X_1 \in B_1) \cap (X_2 \in B_2)$

Satz für stochastisch unabhängige Zufallsvariablen

Es sind äquivalent:

- X_1, \dots, X_n sind stochastisch unabhängig
- $\forall B_i \subseteq S_i : \mathbb{P}(X_i \in B_i \mid \forall 1 \leq i \leq n) = \prod_{i=1}^n \mathbb{P}(X_i \in B_i)$
- Bezeichne mit f_{X_i} die Zähldichte von \mathbb{P}^{X_i} auf S_i . Dann hat die Zähldichte $f_{(X_1, \dots, X_n)}$ von $\mathbb{P}^{(X_1, \dots, X_n)}$ die Form: $f_{(X_1, \dots, X_n)}(t_1, \dots, t_n) = \prod_{i=1}^n f_{X_i}(t_i) \quad \forall t_i \in S_i$

Definition: Hypergeometrischen Verteilung

Das Wahrscheinlichkeitsmaß $\mathbb{P} = \text{Hyp}_{(N,M,n)}$ auf \mathbb{N}_0 gegeben durch die Zähldichte

$$\mathbb{P}^X(\{m\}) = \mathbb{P}(X = m) = \frac{\binom{M}{m} \cdot \binom{N-M}{n-m}}{\binom{N}{n}} \mathbb{1}_S(m) \quad \forall m \in \mathbb{N}_0$$

heißt **hypergeometrische Verteilung**.

Zusammenhang hypergeometrische Verteilung und Binomialverteilung

- Die **hypergeometrische Verteilung** $\text{Hyp}_{(N,M,n)}$ beschreibt die Anzahl der markierten Gegenstände bei n -maligem **Ziehen ohne Zurücklegen** aus N Gegenständen, von denen M markiert sind
- Die **Binomialverteilung** $\text{Bin}_{(n,M/N)}$ beschreibt die Anzahl der markierten Gegenstände bei n -maligem **Ziehen mit Zurücklegen** aus N Gegenständen, von denen M markiert sind

Falls $n \ll N$, dann ist Ziehen mit oder ohne Zurücklegen fast identisch und daher $\text{Hyp}_{(N,M,n)}(\{m\}) \approx \text{Bin}_{(n, \frac{M}{N})}(\{m\}) \quad \forall 0 \leq m \leq n$

Poisson'scher Grenzwertsatz

Für eine große Anzahl an Experimenten n und eine kleine Erfolgswahrscheinlichkeit p kann $\text{Bin}_{(n,p)}$ durch eine strukturell einfachere Verteilung approximiert werden:

$$\lim_{n \rightarrow \infty} \text{Bin}_{(n,p)}(\{k\}) = \lim_{n \rightarrow \infty} \binom{n}{k} p^k (1-p)^{n-k} = e^{-\lambda} \cdot \frac{\lambda^k}{k!} =: \text{Poiss}_\lambda(\{k\}) \quad k \in \mathbb{N}_0$$

Das Wahrscheinlichkeitsmaß Poiss_λ heißt Poissonverteilung mit Parameter λ .

Definition: Faltung

Sind X, Y \mathbb{R} -wertige Zufallsvariablen auf einem diskreten Wahrscheinlichkeitsraum mit Zähldichten f_X von \mathbb{P}^X und f_Y von \mathbb{P}^Y , dann heißt

$$(f_X * f_Y)(z) = \sum_{x \in \mathbb{R}: f_X(x) > 0} f_X(x) \cdot f_Y(z - x) \quad \forall z \in \mathbb{R}$$

die **Faltung** von f_X und f_Y . Hierbei ist $f_X * f_Y$ wieder eine Zähldichte mit Träger $\Omega_T := \{z \in \mathbb{R} \mid \exists x, y \in \mathbb{R} : z = x + y, f_X(x) > 0, f_Y(y) > 0\}$ und die zugehörige diskrete Verteilung $\mathbb{P}^X * \mathbb{P}^Y$ heißt **Faltung** von \mathbb{P}^X und \mathbb{P}^Y .

Satz für die Faltung

Sind X, Y unabhängige \mathbb{R} -wertige Zufallsvariablen auf einem diskreten Wahrscheinlichkeitsraum, so gilt

$$\mathbb{P}^X * \mathbb{P}^Y = \mathbb{P}^{X+Y}$$

4 Wahrscheinlichkeitsmaße auf \mathbb{R}

Kontinuierliche Ergebnisse lassen sich nicht mehr durch eine abzählbare Anzahl an Versuchsausgängen beschreiben. Wahrscheinlichkeiten kann man dann nur noch „gutartigen Mengen“ zuordnen, u.a.:

- Intervalle sind gutartig
- Komplemente gutartiger Mengen sind gutartig
- Abzählbare Vereinigungen gutartiger Mengen sind gutartig

Bezeichne nun mit $\mathcal{A} \subseteq \mathcal{P}(\Omega)$ das System aller „gutartigen“ Mengen.

Definition: σ -Algebra

Sei $\Omega \neq \emptyset$ ein beliebiger Grundraum. Eine Menge $\mathcal{A} \subseteq \mathcal{P}(\Omega)$ heißt **σ -Algebra** auf Ω , falls:

- $\emptyset, \Omega \in \mathcal{A}$
- $A \in \mathcal{A} \implies A^c \in \mathcal{A}$
- $A_n \in \mathcal{A} \forall n \in \mathbb{N} \implies \bigcup_{n \in \mathbb{N}} A_n \in \mathcal{A}$

(Ω, \mathcal{A}) heißt dann **messbarer Raum**. Die Mengen $A \in \mathcal{A}$ heißen **Ereignisse**.

Definition: Borel- σ -Algebra

Die **Borel- σ -Algebra** \mathcal{B} auf \mathbb{R} beschreibt die kleinste σ -Algebra, welche alle Intervalle $(a, b]$ für beliebige $a, b \in \mathbb{R}$ enthält.

Definition: Wahrscheinlichkeitsmaß und Wahrscheinlichkeitsraum

Sei (Ω, \mathcal{A}) ein Messraum mit Grundraum $\Omega \neq \emptyset$ und σ -Algebra \mathcal{A} . Eine Abbildung $\mathbb{P} : \mathcal{A} \rightarrow [0, 1]$ heißt **Wahrscheinlichkeitsmaß** auf (Ω, \mathcal{A}) , falls

- $\mathbb{P}(\Omega) = 1$
- $A_n \in \mathcal{A}, n \in \mathbb{N}, \text{ disjunkt} \implies \mathbb{P}\left(\bigcup_{n \in \mathbb{N}} A_n\right) = \sum_{n \in \mathbb{N}} \mathbb{P}(A_n)$ (σ -Additivität)

$(\Omega, \mathcal{A}, \mathbb{P})$ heißt dann **Wahrscheinlichkeitsraum**.

Sätze und Definitionen für allgemeine Wahrscheinlichkeitsräume

Folgende Sätze und Definitionen übertragen sich sinngemäß, wobei als Ereignisse jeweils nur Mengen aus \mathcal{A} betrachtet werden:

- Rechenregeln für diskrete Wahrscheinlichkeitsmaße
- Bedingte Wahrscheinlichkeiten
- Satz von der Totalen Wahrscheinlichkeit und von Bayes
- Stochastische Unabhängigkeit von Ereignissen

Unterschied: Während diskrete Wahrscheinlichkeitsmaße \mathbb{P} vollständig durch die Zähldichte $f(\omega) := \mathbb{P}(\{\omega\}), \omega \in \Omega$ bestimmt sind, ist dies für allgemeine Wahrscheinlichkeitsmaße falsch!

Definition: Verteilungsfunktion

Ist \mathbb{P} ein Wahrscheinlichkeitsmaß auf $(\mathbb{R}, \mathcal{B}_{\mathbb{R}})$, so gilt für die durch

$$F : \mathbb{R} \rightarrow [0, 1], F(x) := \mathbb{P}((-\infty, x])$$

definierte **Verteilungsfunktion** von \mathbb{P} :

- F ist monoton steigend
- F ist rechtsseitig stetig
- $F(\infty) := \lim_{x \rightarrow \infty} F(x) = 1, F(-\infty) := \lim_{x \rightarrow -\infty} F(x) = 0$

Ist umgekehrt $F : \mathbb{R} \rightarrow [0, 1]$ eine Funktion, die obige Punkte erfüllt, so existiert genau ein Wahrscheinlichkeitsmaß auf $(\mathbb{R}, \mathcal{B}_{\mathbb{R}})$, das F als Verteilungsfunktion besitzt. Für ein diskretes Wahrscheinlichkeitsmaß \mathbb{P} ist die Verteilungsfunktion eine Treppenfunktion.

Definition: Dichten

Sei \mathbb{P} ein Wahrscheinlichkeitsmaß auf $(\mathbb{R}, \mathcal{B}_{\mathbb{R}})$. Existiert eine integrierbare Funktion $f : \mathbb{R} \rightarrow [0, \infty)$, sodass

$$F(x) = \mathbb{P}((-\infty, x]) = \int_{-\infty}^x f(t) dt \quad \forall x \in \mathbb{R}$$

so heißt f Dichte von \mathbb{P} bzw. von der zugehörigen Verteilungsfunktion F . Für $A \in \mathcal{B}_{\mathbb{R}}$ gilt dann

$$\mathbb{P}(A) = \int_{\mathbb{R}} f(x) \cdot \mathbf{1}_A(x) dx =: \int_A f(x) dx$$

Umgekehrt ist jede integrierbare Funktion $f : \mathbb{R} \rightarrow [0, \infty)$ mit $\int_{-\infty}^{\infty} f(t)dt = 1$ Dichte eines Wahrscheinlichkeitsmaßes auf $(\mathbb{R}, \mathcal{B}_{\mathbb{R}})$, das durch obiges F eindeutig festgelegt ist. Falls eine Dichte existiert, ist F stetig.

Achtung: Dichten dürfen nicht mit Zähldichten verwechselt werden!

Definition: Gleichverteilung

Für $-\infty < a < b < \infty$ heißt das Wahrscheinlichkeitsmaß auf $(\mathbb{R}, \mathcal{B}_{\mathbb{R}})$ zur Dichte $f := \frac{1}{b-a} \mathbb{1}_{(a,b]}$ **Gleichverteilung** $U_{(a,b]}$ auf $(a, b]$ und für $a \leq c < d \leq b$ gilt:
 $U_{(a,b]}((c, d]) = \frac{d-c}{b-a}$.

Definition: Exponentialverteilung

Die **Exponentialverteilung** Exp_{λ} mit Parameter $\lambda > 0$ ist gegeben durch die Dichte

$$f_{\lambda}(x) := \frac{1}{\lambda} e^{-x/\lambda} \cdot \mathbb{1}_{[0, \infty)}(x), \quad x \in \mathbb{R}$$

Die Verteilungsfunktion ist gegeben durch $F_{\lambda}(x) = 1 - e^{-x/\lambda}$, $\forall x \geq 0$
 und $F_{\lambda}(x) = 0$ für alle $x < 0$.

Exponentialverteilungen beschreiben Lebensdauern von Dingen, die nicht altern, d.h. die Wahrscheinlichkeit noch y Jahre zu überleben, gegeben dass bereits x Jahre überlebt wurden, hängt nicht von x ab.

Definition: Normalverteilung

Die **Normalverteilung** $N_{(\mu, \sigma^2)}$ mit Parametern $\mu \in \mathbb{R}, \sigma > 0$ ist gegeben durch die Dichte

$$f(x) := \frac{1}{\sqrt{2\pi\sigma^2}} \cdot \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right), \quad x \in \mathbb{R}$$

Die Verteilung $N_{(0,1)}$ wird **Standardnormalverteilung** genannt. Die Verteilungsfunktion von $N_{(0,1)}$ bezeichnet man mit

$$\Phi(x) = \int_{-\infty}^x \frac{1}{\sqrt{2\pi}} e^{-t^2/2} dt$$

Aufgrund der Symmetrie der Standardnormalverteilung zur y-Achse, gilt $\Phi(-x) = 1 - \Phi(x)$ für alle $x \in \mathbb{R}$. Insbesondere ist $\Phi(0) = \frac{1}{2}$.

Für die Verteilungsfunktion der Normalverteilung $N_{(\mu, \sigma^2)}$ gilt

$$F(x) = \Phi\left(\frac{x-\mu}{\sigma}\right)$$

Um Wahrscheinlichkeiten für eine beliebige Normalverteilung zu berechnen, genügt also die Verteilungsfunktion Φ der Standardnormalverteilung:

| x | $\Phi(x)$ | x | $\Phi(x)$ | x | $\Phi(x)$ | x | $\Phi(x)$ | x | $\Phi(x)$ |
|------|-----------|------|-----------|------|-----------|------|-----------|------|-----------|
| 0.00 | 0.5000 | 0.76 | 0.7764 | 1.52 | 0.9357 | 1.84 | 0.9671 | 2.28 | 0.9887 |
| 0.02 | 0.5080 | 0.78 | 0.7823 | 1.54 | 0.9382 | 1.86 | 0.9686 | 2.30 | 0.9893 |
| 0.04 | 0.5160 | 0.80 | 0.7881 | 1.56 | 0.9406 | 1.88 | 0.9699 | 2.32 | 0.9898 |
| 0.06 | 0.5239 | 0.82 | 0.7939 | 1.58 | 0.9429 | 1.90 | 0.9713 | 2.34 | 0.9904 |
| 0.08 | 0.5319 | 0.84 | 0.7995 | 1.60 | 0.9452 | 1.92 | 0.9726 | 2.36 | 0.9909 |
| 0.10 | 0.5398 | 0.86 | 0.8051 | 1.62 | 0.9474 | 1.94 | 0.9738 | 2.38 | 0.9913 |
| 0.12 | 0.5478 | 0.88 | 0.8106 | 1.64 | 0.9495 | 1.96 | 0.9750 | 2.40 | 0.9918 |
| 0.14 | 0.5557 | 0.90 | 0.8159 | 1.66 | 0.9515 | 1.98 | 0.9761 | 2.42 | 0.9922 |
| 0.16 | 0.5636 | 0.92 | 0.8212 | 1.68 | 0.9535 | 2.00 | 0.9772 | 2.44 | 0.9927 |
| 0.18 | 0.5714 | 0.94 | 0.8264 | 1.70 | 0.9554 | 2.02 | 0.9783 | 2.46 | 0.9931 |
| 0.20 | 0.5793 | 0.96 | 0.8315 | 1.72 | 0.9573 | 2.04 | 0.9793 | 2.48 | 0.9934 |
| 0.22 | 0.5871 | 0.98 | 0.8365 | 1.74 | 0.9591 | 2.06 | 0.9803 | 2.50 | 0.9938 |
| 0.24 | 0.5948 | 1.00 | 0.8413 | 1.76 | 0.9608 | 2.08 | 0.9812 | 2.52 | 0.9941 |
| 0.26 | 0.6026 | 1.02 | 0.8461 | 1.78 | 0.9625 | 2.10 | 0.9821 | 2.54 | 0.9945 |
| 0.28 | 0.6103 | 1.04 | 0.8508 | 1.80 | 0.9641 | 2.12 | 0.9830 | 2.56 | 0.9948 |
| 0.30 | 0.6179 | 1.06 | 0.8554 | 1.82 | 0.9656 | 2.14 | 0.9838 | 2.58 | 0.9951 |

Lineare Transformation der Normalverteilung

Sei X eine Zufallsvariable mit $X \sim N_{(\mu, \sigma^2)}$, dann gilt für beliebige $m \in \mathbb{R}, s > 0$:

$$Y := m + sX \sim N_{(m+s\mu, s^2\sigma^2)}$$

Aus $X \sim N_{(\mu, \sigma^2)}$ folgt $\frac{X-\mu}{\sigma} \sim N_{(0,1)}$.

Definition: Zufallsvariable, Messbarkeit und Verteilung

Eine Zufallsvariable X ist nur noch definiert, wenn das Urbild von X eine „gutartige“ Menge ist.

Seien (Ω, \mathcal{A}) , (S, \mathcal{C}) messbare Räume und $X : \Omega \rightarrow S$ eine Abbildung. X heißt S -wertige **Zufallsvariable**, falls $X^{-1}(C) \in \mathcal{A}$ für alle $C \in \mathcal{C}$ ist.

Man schreibt $X : (\Omega, \mathcal{A}) \rightarrow (S, \mathcal{C})$ und sagt, dass X $(\mathcal{A}, \mathcal{C})$ -**messbar** ist. Die sogenannte **Verteilung** von X unter \mathbb{P} wird durch das Wahrscheinlichkeitsmaß

$$\mathbb{P}^X(C) := \mathbb{P}(X^{-1}(C)) = \mathbb{P}(X \in C), \quad C \in \mathcal{C}$$

auf (S, \mathcal{C}) definiert.

Definition: Verteilungsfunktion und Dichte von Zufallsvariablen

Sei $X : (\Omega, \mathcal{A}) \rightarrow (S, \mathcal{C})$ eine \mathbb{R} -wertige Zufallsvariable auf dem Wahrscheinlichkeitsraum $(\Omega, \mathcal{A}, \mathbb{P})$.

- Die Verteilungsfunktion der Verteilung \mathbb{P}^X von X

$$F_X : \mathbb{R} \rightarrow [0, 1], \quad x \mapsto \mathbb{P}^X((-\infty, x]) = \mathbb{P}(X \leq x)$$

wird auch **Verteilungsfunktion** von X genannt.

- X heißt **stetige Zufallsvariable**, falls F_X eine Dichte f_X besitzt:

$$\mathbb{P}(X \leq x) = \int_{-\infty}^x f_X(t) dt \quad \forall x \in \mathbb{R}$$

f_X heißt dann auch **Dichte** von X .

$k\sigma$ -Regeln für die Normalverteilung

Für $X \sim N(\mu, \sigma^2)$ und alle $t > 0$ gilt

$$\mathbb{P}(|X - \mu| \leq \sigma t) = 2 \cdot \Phi(t) - 1$$

und insbesondere

$$\mathbb{P}(|X - \mu| \leq k\sigma) = \begin{cases} 0,6827, & k = 1 \\ 0,9545, & k = 2 \\ 0,9973, & k = 3 \end{cases}$$

Definition: Borel- σ -Algebren auf \mathbb{R}^n

Borel- σ -Algebren, Verteilungsfunktion und Dichten kann man analog auch für $\Omega = \mathbb{R}^n$ definieren. Die **Borel- σ -Algebra** $\mathcal{B}_{\mathbb{R}^n}$ auf \mathbb{R}^n wird definiert als die kleinste σ -Algebra, die alle Rechteckmengen $\bigtimes_{i=1}^n (a_i, b_i]$ mit $-\infty < a_i < b_i < \infty$ für alle $i \in \{1, \dots, n\}$ enthält.

Definition: Multivariate Verteilungsfunktion

Ist \mathbb{P} ein Wahrscheinlichkeitsmaß auf $(\mathbb{R}^n, \mathcal{B}_{\mathbb{R}^n})$, so wird die zugehörige **multivariate Verteilungsfunktion** F definiert durch

$$F(x_1, \dots, x_n) := \mathbb{P}\left(\bigtimes_{i=1}^n (-\infty, x_i]\right), \quad (x_1, \dots, x_n) \in \mathbb{R}^n$$

Definition: Dichten auf \mathbb{R}^n

Sei \mathbb{P} ein Wahrscheinlichkeitsmaß auf $(\mathbb{R}^n, \mathcal{B}_{\mathbb{R}^n})$ mit multivariater Verteilungsfunktion F . Existiert eine Abbildung $f : \mathbb{R}^n \rightarrow [0, \infty)$, sodass für alle $(x_1, \dots, x_n) \in \mathbb{R}^n$

$$F(x_1, \dots, x_n) = \int_{-\infty}^{x_1} \int_{-\infty}^{x_2} \cdots \int_{-\infty}^{x_n} f(t_1, \dots, t_n) dt_n \dots dt_2 dt_1$$

gilt, so heißt f **Dichte** von \mathbb{P} bzw. von F .

Es gilt dann $\forall B \in \mathcal{B}_{\mathbb{R}^n}$:

$$\mathbb{P}(B) = \int_B f(t) dt = \int_{-\infty}^{\infty} \cdots \int_{-\infty}^{\infty} \mathbb{1}_B(t_1, \dots, t_n) \cdot f(t_1, \dots, t_n) dt_n \dots dt_1$$

Insbesondere gilt für jede Dichte f : $\int_{-\infty}^{\infty} \cdots \int_{-\infty}^{\infty} f(t_1, \dots, t_n) dt_n \dots dt_1 = 1$

und für $B = (a_1, b_1] \times \cdots \times (a_n, b_n]$, $a_i < b_i$: $\mathbb{P}(B) = \int_{a_1}^{b_1} \cdots \int_{a_n}^{b_n} f(t_1, \dots, t_n) dt_n \dots dt_1$.

Definition: Zufallsvektoren

Ist (Ω, \mathcal{A}) ein messbarer Raum und $X_i : \Omega \rightarrow \mathbb{R}$, $1 \leq i \leq n$, so gilt $\forall 1 \leq i \leq n$:

$$X = (X_1, \dots, X_n) : \Omega \rightarrow \mathbb{R}^n \text{ } (\mathcal{A}, \mathcal{B}_{\mathbb{R}^n})\text{-messbar} \iff X_i : \Omega \rightarrow \mathbb{R} \text{ } (\mathcal{A}, \mathcal{B}_{\mathbb{R}})\text{-messbar}$$

In dem Fall wird X auch n -dimensionaler **Zufallsvektor** genannt. Die multivariate Verteilungsfunktion von \mathbb{P}^X

$$F_X(x_1, \dots, x_n) := \mathbb{P}(X_1 \leq x_1, X_2 \leq x_2, \dots, X_n \leq x_n)$$

heißt **gemeinsame Verteilungsfunktion** von X_1, \dots, X_n . Besitzt F_X eine Dichte f_X , dann heißt X **stetig verteilt** und f_X heißt **gemeinsame Dichte** von X_1, \dots, X_n . Es gilt dann $\mathbb{P}^X(B) = \mathbb{P}(X \in B) = \int_B f_X(t) dt$, $B \in \mathcal{B}_{\mathbb{R}^n}$.

Definition: Randverteilungen

Ist $X = (X_1, \dots, X_n)$ ein Zufallsvektor auf $(\Omega, \mathcal{A}, \mathbb{P})$, so heißen die Verteilungen \mathbb{P}^{X_i} **Randverteilungen/Marginalverteilungen**. Die Verteilungsfunktion F_i von \mathbb{P}^{X_i} bzw. X_i berechnet sich wie folgt:

$$\begin{aligned} F_i(x) &= \mathbb{P}(X_1 < \infty, \dots, X_{i-1} < \infty, X_i \leq x, X_{i+1} < \infty, \dots, X_n < \infty) \\ &= F(\infty, \dots, \infty, x, \infty, \dots, \infty), \end{aligned}$$

wobei x an der i -ten Stelle steht.

Satz über die Dichte einer Komponente eines Zufallsvektors

Besitzt die Zufallsvariable $X = (X_1, \dots, X_n)$ eine gemeinsame Dichte $f : \mathbb{R}^n \rightarrow [0, \infty)$, so hat X_i die Dichte $f_i : \mathbb{R} \rightarrow [0, \infty)$ mit

$$f_i(x) = \int_{-\infty}^{\infty} \cdots \int_{-\infty}^{\infty} f(t_1, \dots, t_{i-1}, x, t_{i+1}, \dots, t_n) dt_n \cdots dt_{i+1} dt_{i-1} \cdots dt_1$$

für alle $x \in \mathbb{R}$.

Definition: Unabhängigkeit von Zufallsvariablen

Zufallsvariablen $X_1, \dots, X_n : (\Omega, \mathcal{A}) \rightarrow (\mathbb{R}, \mathcal{B}_{\mathbb{R}})$ heißen **stochastisch unabhängig**, wenn die Ereignisse $\{X_1 \in B_1\}, \dots, \{X_n \in B_n\}$ für alle $B_1, \dots, B_n \in \mathcal{B}_{\mathbb{R}}$ stochastisch unabhängig sind.

Satz für stochastisch unabhängige Zufallsvariablen

Für Zufallsvariablen $X_i : (\Omega, \mathcal{A}) \rightarrow (\mathbb{R}, \mathcal{B}_{\mathbb{R}})$ mit Verteilungsfunktionen F_{X_i} sind äquivalent:

- X_1, \dots, X_n sind stochastisch unabhängig
- $\mathbb{P}(X_1 \in B_1, \dots, X_n \in B_n) = \prod_{i=1}^n \mathbb{P}(X_i \in B_i) \quad \forall B_1, \dots, B_n \in \mathcal{B}_{\mathbb{R}}$
- $\mathbb{P}(X_1 \leq x_1, \dots, X_n \leq x_n) = \prod_{i=1}^n \mathbb{P}(X_i \leq x_i) = \prod_{i=1}^n F_{X_i}(x_i) \quad \forall x_1, \dots, x_n \in \mathbb{R}$

Zufallsvariablen sind also genau dann unabhängig, wenn die Verteilungsfunktion ihrer gemeinsamen Verteilung das Produkt ihrer Verteilungsfunktionen ist.

Dichten unabhängiger Zufallsvariablen

Seien $X_i : \Omega \rightarrow \mathbb{R}$ für $i \in \{1, \dots, n\}$ Zufallsvariablen auf einem Wahrscheinlichkeitsraum $(\Omega, \mathcal{A}, \mathbb{P})$. Falls alle Randverteilungen \mathbb{P}^{X_i} jeweils eine Dichte f_i besitzen, dann sind äquivalent:

- X_1, \dots, X_n sind stochastisch unabhängig:
- $\mathbb{P}^{(X_1, \dots, X_n)}$ besitzt eine Dichte f gegeben durch $f(x_1, \dots, x_n) := \prod_{i=1}^n f_i(x_i)$

Blockungslemma

Seien $X_{11}, X_{12}, \dots, X_{1n_1}, X_{21}, \dots, X_{2n_2}, \dots, X_{k1}, \dots, X_{kn_k}$ stochastisch unabhängige Zufallsvariablen und $g_1 : \mathbb{R}^{n_1} \rightarrow \mathbb{R}, g_2 : \mathbb{R}^{n_2} \rightarrow \mathbb{R}, \dots, g_k : \mathbb{R}^{n_k} \rightarrow \mathbb{R}$ Funktionen. Dann sind auch die Zufallsvariablen

$$Y_1 := g_1(X_{11} \dots, X_{1n_1}), Y_2 := g_2(X_{21} \dots, X_{2n_2}), \dots, Y_k := g_k(X_{k1} \dots, X_{kn_k})$$

stochastisch unabhängig. Funktionen von disjunkten Blöcken unabhängiger Zufallsvariablen sind also wieder unabhängig.

Definition: Faltung für Verteilungen mit Dichten

- Sind $X, Y : (\Omega, \mathcal{A}) \rightarrow (\mathbb{R}, \mathcal{B}_{\mathbb{R}})$ unabhängige Zufallsvariablen auf einem Wahrscheinlichkeitsraum $(\Omega, \mathcal{A}, \mathbb{P})$ so wird die Verteilung \mathbb{P}^{X+Y} die **Faltung** von \mathbb{P}^X und \mathbb{P}^Y genannt. Schreibe dafür: $\mathbb{P}^X * \mathbb{P}^Y$
- Besitzt X eine Dichte f_X und Y eine Dichte f_Y , so ist

$$f_X * f_Y(z) = \int_{-\infty}^{\infty} f_X(x) f_Y(z-x) dx, \quad z \in \mathbb{R}$$

eine Dichte von $\mathbb{P}^X * \mathbb{P}^Y$, d.h. $f_{X+Y} = f_X * f_Y$

Definition: Gamma-Verteilung

Die Zufallsvariable X hat eine **Gamma-Verteilung** mit Parametern $\alpha > 0$ und $\beta > 0$, falls X die Dichte

$$f(t) = \frac{\beta^\alpha}{\Gamma(\alpha)} t^{\alpha-1} e^{-\beta t} \mathbb{1}_{(0,\infty)}(t), \quad t \in \mathbb{R}$$

mit Gamma-Funktion $\Gamma(t) := \int_0^\infty x^{t-1} e^{-x} dx$, $t > 0$ besitzt.

Additionsgesetze

| $X \sim$ | $Y \sim$ | $X + Y \sim$ |
|-----------------------|----------------------|-------------------------------|
| $\text{Bin}_{m,p}$ | $\text{Bin}_{n,p}$ | $\text{Bin}_{m+n,p}$ |
| Pois_λ | Pois_μ | $\text{Pois}_{\lambda+\mu}$ |
| N_{μ,σ^2} | N_{ν,τ^2} | $N_{\mu+\nu,\sigma^2+\tau^2}$ |
| $\Gamma_{\mu,\beta}$ | $\Gamma_{\nu,\beta}$ | $\Gamma_{\mu+\nu,\beta}$ |
| Exp_λ | Exp_λ | $\Gamma_{2,\lambda}$ |

Beachte: In jedem Fall sind X und Y als stochastisch unabhängig vorausgesetzt.

Verteilungsfunktion von Maximum und Minimum

Seien X_1, \dots, X_n stochastisch unabhängige Zufallsvariablen mit den Verteilungsfunktionen F_{X_1}, \dots, F_{X_n} . Dann gilt:

- $U := \max(X_1, \dots, X_n)$ besitzt die Verteilungsfunktion

$$F_U(t) = \prod_{j=1}^n F_{X_j}(t), \quad t \in \mathbb{R}$$

- $V := \min(X_1, \dots, X_n)$ besitzt die Verteilungsfunktion

$$F_V(t) = 1 - \prod_{j=1}^n (1 - F_{X_j}(t)), \quad t \in \mathbb{R}$$

5 Erwartungswerte und Momente von Zufallsvariablen

Definition: Erwartungswert auf einem diskreten Wahrscheinlichkeitsraum

Der **Erwartungswert** einer \mathbb{R} -wertigen Zufallsvariable $X : \Omega \rightarrow \mathbb{R}$ auf einem diskreten Wahrscheinlichkeitsraum (Ω, \mathbb{P}) ist definiert als:

$$\mathbb{E}_{\mathbb{P}}[X] := \mathbb{E}[X] := \sum_{x \in X(\Omega)} x \cdot \mathbb{P}(X = x) = \sum_{x \in X(\Omega)} x \cdot \mathbb{P}^X(\{x\})$$

falls $\sum_{x \in X(\Omega)} |x| \cdot \mathbb{P}(X = x) < \infty$. $\mathbb{E}_{\mathbb{P}}[X]$ heißt auch **Mittelwert** von \mathbb{P}^X .

Definition: Erwartungswert für stetige Zufallsvariablen

Der **Erwartungswert** einer stetigen Zufallsvariable X mit Dichte f_X wird definiert als:

$$\mathbb{E}[X] = \int_{-\infty}^{\infty} x \cdot f_X(x) dx$$

falls $\int_{-\infty}^{\infty} |x| \cdot f_X(x) dx < \infty$. $\mathbb{E}[X]$ heißt auch **Mittelwert** von \mathbb{P}^X .

Transformationssatz

Sei $(\Omega, \mathcal{A}, \mathbb{P})$ ein Wahrscheinlichkeitsraum, $X : \Omega \rightarrow S$ eine diskrete/stetige Zufallsvariable mit (Zähl-)Dichte f_X und $g : S \rightarrow \mathbb{R}$ eine Funktion. Die Zufallsvariable $g(X) = g \circ X$ besitzt genau dann einen endlichen Erwartungswert bzgl. \mathbb{P} , wenn g einen endlichen Erwartungswert bzgl. \mathbb{P}^X besitzt. In diesem Fall gilt:

$$\mathbb{E}_{\mathbb{P}}[g(X)] = \mathbb{E}_{\mathbb{P}^X}[g] = \begin{cases} \sum_{x \in S} g(x) \cdot f_X(x) & \text{falls } X \text{ diskret} \\ \int_{-\infty}^{\infty} g(x) \cdot f_X(x) dx & \text{falls } X \text{ stetig} \end{cases}$$

Der Transformationssatz gilt auch für Zufallsvariablen X, Y mit gemeinsamer Zähldichte $f_{X,Y}$, d.h.

$$\mathbb{E}[g(X, Y)] = \begin{cases} \sum_{x \in X(\Omega)} \sum_{y \in Y(\Omega)} g(x, y) \cdot f_{X,Y}(x, y) & \text{falls } X, Y \text{ diskret} \\ \int_{-\infty}^{\infty} \left(\int_{-\infty}^{\infty} g(x, y) \cdot f_{X,Y}(x, y) dy \right) dx & \text{falls } X \text{ stetig} \end{cases}$$

Rechenregeln für Erwartungswerte

Seien X, Y diskrete/stetige Zufallsvariablen auf einem Wahrscheinlichkeitsraum $(\Omega, \mathcal{A}, \mathbb{P})$, die Erwartungswerte besitzen. Dann gilt:

- $\mathbb{E}[aX + Y] = a \cdot \mathbb{E}[X] + \mathbb{E}[Y]$ für alle $a \in \mathbb{R}$ (**Linearität**)
- Gilt $X \leq Y$, dann folgt $\mathbb{E}[X] \leq \mathbb{E}[Y]$ (**Monotonie**)
- Wenn f_X symmetrisch zu $x = a$ ist, dann gilt $\mathbb{E}[X] = a$

Siebformel von Sylvester-Poincaré

Seien $A_1, \dots, A_n \in \mathcal{A}$ Ereignisse im einem diskreten Wahrscheinlichkeitsraum $(\Omega, \mathcal{A}, \mathbb{P})$. Dann gilt:

$$\mathbb{P}\left(\bigcup_{i=1}^n A_i\right) = \sum_{I \subseteq \{1, \dots, n\}, I \neq \emptyset} (-1)^{|I|+1} \cdot \mathbb{P}\left(\bigcap_{i \in I} A_i\right)$$

Darstellungsformel für nicht-negative Zufallsvariablen

Ist X eine \mathbb{N}_0 -wertige oder \mathbb{R}_+ -wertige Zufallsvariable, so gilt

$$\mathbb{E}[X] = \begin{cases} \sum_{n=1}^{\infty} \mathbb{P}(X \geq n) & \text{falls } X \text{ diskret} \\ \int_0^{\infty} \mathbb{P}(X \geq x) & \text{falls } X \text{ stetig} \end{cases}$$

Multiplikationsformel für Erwartungswerte

Sind X und Y stochastisch unabhängige reellwertige Zufallsvariablen mit Erwartungswerten $\mathbb{E}[X]$ und $\mathbb{E}[Y]$, so gilt

$$\mathbb{E}[X \cdot Y] = \mathbb{E}[X] \cdot \mathbb{E}[Y]$$

Die Umkehrung gilt im Allgemeinen nicht!

Definition: Variation, Standardabweichung und Momente

- Existieren $\mathbb{E}[X]$ und $\mathbb{E}[X^2]$ so ist die **Varianz** von X durch

$$Var(X) = \mathbb{E}[(X - \mathbb{E}[X])^2] = \begin{cases} \sum_{x \in X(\Omega)} (x - \mathbb{E}[X])^2 f_X(x) & \text{falls } X \text{ diskret} \\ \int_{-\infty}^{\infty} (x - \mathbb{E}[X])^2 f_X(x) dx & \text{falls } X \text{ stetig} \end{cases}$$

definiert. $\sqrt{Var(X)}$ heißt **Standardabweichung** von X .

- Für $k \in \mathbb{N}$ heißt $\mathbb{E}[X^k]$ das **k -te Moment von X** . Dabei ist $X^k : \Omega \rightarrow \mathbb{R}$ definiert durch $X^k(\omega) = (X(\omega))^k$

Eigenschaften der Varianz

- $Var(a \cdot X + b) = a^2 \cdot Var(X)$ für alle $a, b \in \mathbb{R}$. Die Varianz ist nicht linear!
- $Var(X) = \mathbb{E}[X^2] - \mathbb{E}[X]^2$, also $\mathbb{E}[X]^2 \leq \mathbb{E}[X^2]$, da $0 \leq Var(X)$
- $\mathbb{E}[(X - a)^2] = Var(X) + (\mathbb{E}[X] - a)^2$ für alle $a \in \mathbb{R}$
- Die Minimalstelle der Funktion $a \mapsto \mathbb{E}[(X - a)^2]$ ist $a = \mathbb{E}[X]$

Wichtige Beispiele

- Wenn $X \sim Ber_p$ mit $p \in [0, 1]$, dann gilt $\mathbb{E}[X] = p$ und $Var(X) = p(1 - p)$
- Wenn $X \sim Poiss_\lambda$, dann gilt $\mathbb{E}[X^2] = \lambda^2 + \lambda$ und $Var(X) = \lambda$
- Wenn $X \sim U([a, b])$ gleichverteilt, dann gilt $\mathbb{E}[X^2] = \frac{b^2 + ab + a^2}{3}$ und $Var(X) = \frac{(b-a)^2}{12}$
- Wenn $Y \sim N_{(0,1)}$, dann gilt $\mathbb{E}[Y] = 0$ und $Var(Y) = 1$ sowie wegen $X := \sigma Y + \mu \sim N_{(0,1)}$ folgt $Var(X) = \sigma^2$

Markov- und Chebyshev-Ungleichung

- **Markov-Ungleichung:** $\mathbb{P}(|X| \geq c) \leq \frac{\mathbb{E}[|X|]}{c} \quad \forall c > 0$
- **Chebyshev-Ungleichung:** $\mathbb{P}(|X - \mathbb{E}[X]| \geq c) \leq \frac{Var(X)}{c^2} \quad \forall c > 0$

Definition: Kovarianz und Korrelation

Seien X und Y Zufallsvariablen.

$$Cov(X, Y) = \mathbb{E}[(X - \mathbb{E}[X]) \cdot (Y - \mathbb{E}[Y])] = \mathbb{E}[XY] - \mathbb{E}[X] \cdot \mathbb{E}[Y]$$

heißt die **Kovarianz** von X und Y .

$$Corr(X, Y) = \frac{Cov(X, Y)}{\sqrt{Var(X) \cdot Var(Y)}}$$

heißt **Korrelation** von X und Y , falls $Var(X) > 0$ und $Var(Y) > 0$. X und Y heißen **unkorreliert**, falls $Cov(X, Y) = 0$.

Die Kovarianz ist bilinear, d.h. $Cov(aX + b, cY + d) = ac \cdot Cov(X, Y)$.

Ist Z eine weitere Zufallsvariable, so gilt $Cov(X, Y + Z) = Cov(X, Y) + Cov(X, Z)$. Jede unabhängige Zufallsvariable ist unkorreliert, umgekehrt aber nicht!

Varianz von Summen von Zufallsvariablen

Für Zufallsvariablen $X_1 \cdot X_n$ gilt:

$$\text{Var}\left(\sum_{i=1}^n X_i\right) = \sum_{i=1}^n \text{Var}(X_i) + 2 \sum_{1 \leq i < j \leq n} \text{Cov}(X_i, X_j)$$

Sind die Variablen unabhängig (oder schwächer: unkorreliert), so gilt insbesondere:

$$\text{Var}\left(\sum_{i=1}^n X_i\right) = \sum_{i=1}^n \text{Var}(X_i)$$

Definition: Median einer Zufallsvariable

Neben dem Erwartungswert gibt es weitere Parameter, die „mittlere Werte“ einer Zufallsvariable beschreiben. Eine Zahl $m(X)$ heißt **Median** von X bzw. \mathbb{P}^X , falls gilt:

$$\mathbb{P}(X \leq m(X)) \geq \frac{1}{2} \text{ und } \mathbb{P}(X \geq m(X)) \geq \frac{1}{2}$$

Mediane sind im Allgemeinen nicht eindeutig. Der Median ist ein **Lageparameter**, d.h. es gilt: m ist Median von $X \iff am + b$ ist Median von $aX + b$.

Definition: Quantil

Ein Quantil ist eine Verallgemeinerung des Medians. Für X mit Verteilungsfunktion F_X und $0 < p < 1$ heißt

$$t_p := t_p(X) := F_X^{-1}(p) := \inf\{x \in \mathbb{R} : F_X(x) \geq p\}$$

p -Quantil von F_X bzw. X . $t_{1/2}$ heißt Median, $t_{1/4}$ **unteres Quartil** und $t_{3/4}$ **oberes Quartil**.

6 Grenzwertsätze

Oft betrachtet man Summen von n Zufallsvariablen von der Art $\sum_{i=1}^n X_i$ für $n \rightarrow \infty$, die in der Regel nicht exakt berechenbar ist. Ziel: Finde eine gute Approximation dafür.

Schwaches Gesetz der großen Zahlen

Seien X_i unkorrelierte Zufallsvariablen mit Erwartungswert $\mathbb{E}[X_i]$ und es existiere M , sodass $\text{Var}(X_i) \leq M < \infty$ für alle $i \in \mathbb{N}$. Dann gilt für alle $\varepsilon > 0$:

$$\mathbb{P}\left(\frac{1}{n} \left| \sum_{i=1}^n (X_i - \mathbb{E}[X_i]) \right| \geq \varepsilon\right) \leq \frac{M}{n\varepsilon^2} \rightarrow 0 \quad \text{für } n \rightarrow \infty$$

Definition: Stochastische Konvergenz

Seien Y, Y_n \mathbb{R} -wertige Zufallsvariablen. Y_n **konvergiert stochastisch** gegen Y , falls

$$\forall \varepsilon > 0 : \quad \mathbb{P}(|Y_n - Y| \geq \varepsilon) \rightarrow 0 \quad (n \rightarrow \infty)$$

Wir schreiben dafür $Y_n \xrightarrow{\mathbb{P}} Y$.

Asymptotische Verteilung

Für identische, unabhängige Zufallsvariablen $(X_i)_{i \geq 1}$ mit $\mathbb{E}[X_i] = \mu$ und $\sigma^2 := \text{Var}(X_i)$ liefert das Gesetz der großen Zahlen den Grenzwert für die Partialsummen:

$$\frac{1}{n} \sum_{i=1}^n X_i \xrightarrow{\mathbb{P}} \mu \quad (n \rightarrow \infty).$$

Wie verhält sich die Verteilung von $\sum_{i=1}^n X_i$ für $n \rightarrow \infty$? Es gilt:

$$\mathbb{E}\left[\sum_{i=1}^n X_i\right] = n\mu \quad \text{und} \quad \text{Var}\left(\sum_{i=1}^n X_i\right) = n\sigma^2$$

Wir standardisieren nun mit $S_n := \frac{1}{\sqrt{n\sigma^2}} \sum_{i=1}^n (X_i - \mu)$, sodass $\mathbb{E}[S_n] = 0$ und $\text{Var}(S_n) = 1$ für alle $n \in \mathbb{N}$. Das führt zum zentralen Grenzwertsatz.

Zentraler Grenzwertsatz

Seien X_i identisch und unabhängig verteilte Zufallsvariablen, d.h. $\mathbb{P}^{X_i} = \mathbb{P}^{X_1}$ mit $\mathbb{E}[X_i] = \mu$ und $\sigma^2 := \text{Var}(X_i)$. Dann gilt für alle $x \in \mathbb{R}$:

$$\mathbb{P}\left(\frac{1}{\sqrt{n\sigma^2}} \sum_{i=1}^n (X_i - \mu) \leq x\right) \xrightarrow{n \rightarrow \infty} \Phi(x),$$

wobei Φ die Standardnormalverteilung ist.

Zentraler Grenzwertsatz von Moivre-Laplace

Ist Y_n eine $\text{Bin}_{(n,p)}$ -verteilte Zufallsvariable mit $p \in (0, 1)$ so gilt:

$$\mathbb{P}\left(a < \frac{Y_n - np}{\sqrt{np \cdot (1-p)}} \leq b\right) \xrightarrow{n \rightarrow \infty} \Phi(b) - \Phi(a),$$

7 Statistik

Unterteilung der Statistik

- Beschreibende (deskriptive) Statistik: Aussagen werden auf den betrachteten Daten getroffen
- Beurteilende (schließende, induktive) Statistik: Aus vorliegenden Daten werden Rückschlüsse auf allgemeine Gültigkeit getroffen.

Definition: Stichprobe

Sei \mathcal{X} die Menge aller Beobachtungen in einem Zufallsexperiment. Bezeichne mit $x_i \in \mathcal{X}$ das i -te Ergebnis, dann heißt $x := (x_1, \dots, x_n)$ **Stichprobe** vom Umfang $n \in \mathbb{N}$. \mathcal{X} heißt **Stichprobenraum**.

Absolute und relative Häufigkeit

Für $a \in \mathcal{X}$ und eine Stichprobe x ist die **absolute** bzw. **relative Häufigkeit** von a in x definiert durch

$$H_x(a) := \sum_{i=1}^n \mathbb{1}_{\{x_i=a\}} \quad \text{bzw.} \quad h_x(a) := \frac{H_x(a)}{n}$$

Definition: Merkmal

Die bei einem stochastischen Vorgang beobachtbaren Größen heißen **Merkmale**. Werte, die von Merkmalen angenommen werden können, heißen **Merkmalsausprägungen**.

Definition: Empirische Verteilungsfunktion

Die Funktion

$$F_n : \mathbb{R} \rightarrow [0, 1], \quad t \mapsto F_n(t) := \frac{1}{n} \sum_{i=1}^n \mathbb{1}_{\{x_i \leq t\}}$$

heißt **empirische Verteilungsfunktion** von $x = (x_1, \dots, x_n)$. Für ein diskretes Merkmal gilt $F_n(t) = \sum_{a \leq t} h_x(a)$.

Definition: Histogramm

Das **Histogramm** ist definiert durch

$$\hat{f}_n^{hist} := \sum_{k=1}^K d_k \mathbb{1}_{(a_k, a_{k+1}]}(y), \quad \text{wobei}$$

- $d_k := \frac{n_k}{a_{k+1} - a_k}$ (Gewichtung nach Größe der Klasse)
- $n_k := \frac{1}{n} \sum_{i=1}^n \mathbb{1}_{\{a_k < x_i \leq a_{k+1}\}}$ (Relative Häufigkeit der Klasse)

Kenngrößen

- $\bar{x} := \frac{1}{n} \sum_{i=1}^n x_i$ (Stichproben-Mittel)
- $s_x^2 := \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$ (Stichproben-Varianz)
- $s_x := \sqrt{s_x^2}$ (Stichprobenstandardabweichung)
- $v_x := \frac{s_x}{\bar{x}}$ (Stichprobenvariationskoeffizient)
- Sei $x_{()} := (x_{(1)}, \dots, x_{(n)})$ eine aufsteigend sortierte Stichprobe.

$$\tilde{x} := \begin{cases} x_{(\frac{n+1}{2})} & \text{falls } n \text{ ungerade} \\ \frac{1}{2} \cdot (x_{(\frac{n}{2})} + x_{(\frac{n}{2}+1)}) & \text{falls } n \text{ gerade} \end{cases}$$

heißt **Stichprobenmedian**.

- Für $p \in (0, 1)$ und $k := \lfloor n \cdot p \rfloor$ heißt

$$\tilde{x}_p := \begin{cases} x_{(k+1)} & \text{falls } n \cdot p \notin \mathbb{N} \\ \frac{1}{2} \cdot (x_{(k)} + x_{(k+1)}) & \text{sonst} \end{cases}$$

das **Stichproben- p -Quantil**.

- Für $\alpha \in [0, 0.5]$ und $k := \lfloor n \cdot \alpha \rfloor$ ist $\bar{x}_\alpha := \frac{1}{n-2 \cdot k} \cdot (x_{(k+1)} + \dots + x_{(n-k)})$ das **α -getrimmte Stichprobenmittel**.

Beschreibung zweidimensionaler Daten

Ein (**parametrisches**) **Regressionsmodell** versucht die Beobachtungen mit einer Regressionsfunktion f_β für ein geeignetes $\beta \in \mathbb{R}^p$ möglichst gut zu beschreiben, d.h. $y_i \approx f_\beta(x_i)$ für alle $i = 1, \dots, n$.

Einfache lineare Regression

Die **Regressionsgerade** $y = a^* + b^*x$ ist bestimmt durch a^*, b^* als Lösung von $\min_{a, b \in \mathbb{R}} \sum_{i=1}^n (y_i - a - bx_i)^2$ (**Kleinste-Quadrate-Methode**). Lösung ist gegeben durch

$$b^* = \frac{\sum_{j=1}^n (x_j - \bar{x})(y_j - \bar{y})}{\sum_{j=1}^n (x_j - \bar{x})^2} \quad \text{und} \quad a^* = \bar{y} - b^* \bar{x}$$

Der (**empirische**) (**Pearson-**) **Korrelationskoeffizient** von $(x_1, y_1), \dots, (x_n, y_n)$ ist gegeben durch

$$r_{xy} = \frac{\frac{1}{n-1} \sum_{j=1}^n (x_j - \bar{x})(y_j - \bar{y})}{s_x s_y}$$

wobei s_k die Stichprobenstandardabweichung von k ist. Damit gilt $b^* = r_{xy} \frac{s_y}{s_x}$.

Eigenschaften von r_{xy}

- Es gilt $-1 \leq r_{xy} \leq 1$
- Je nachdem ob r_{xy} positiv oder negativ ist, liegt ein ansteigender oder fallender linearer Trend vor
- Bei linearen Datentransformationen der Form $\tilde{x} = a \cdot x_j + b$, $\tilde{y} = c \cdot y_j + d$ ändert sich r_{xy} nicht, d.h. $r_{\tilde{x}\tilde{y}} = r_{xy}$